TRABAJO PRACTICO 2

INFORME

Grupo 3: Máximo Hernán Gómez (909.123), Franco Andrés Marelli (898.643)

Familiarizándose con la EPH y limpieza

Para el INDEC, el empleo informal comprende a la población ocupada que cumple con alguna de las siguientes condiciones. Para el caso de los asalariados, si existe una relación laboral en la que el trabajador no tiene descuento jubilatorio (es decir, no tiene cobertura de seguridad social). Para cuentapropistas, patrones o empleadores si operan en empresas del sector informal, que no están reconocidas con el fin de producir bienes o servicios. Por último, el INDEC considera informal a los trabajadores familiares sin remuneración, dado que no están sujetos a ningún tipo de legislación de protección laboral. La tasa se calcula dividiendo la población ocupada informal por el total de la población ocupada.

Una vez descargadas las bases de datos, se seleccionaron las variables de identificación y categóricas a continuación.

REGION: Código de región
PONDERA: Pond. por aglomerado urbano
CH04: Sexo
CH06: Años cumplidos
CH07: Estado civil
CH08: Tipo de cobertura médica
NIVEL_ED: Nivel de educación
ESTADO: Condición de actividad
CAT_OCUP: Categoría ocupacional
EMPLEO: Formal/Informal
SECTOR: Formal/Informal/Hogares
PP04C: Número de trabajadores en ocupación principal
PP04D_COD: Código de ocupación
P21: Ingreso de ocupación principal
P47T: Ingresos totales
PP04G: Lugar habitual de trabajo
PP04A: Ocup. Princ. Publico/Privada

Realizamos una limpieza de datos, en donde se buscaron valores sin sentido, y encontramos valores atípicos en las columnas de ingresos (P21 y P47T) y en la columna de años cumplidos (CH06). Para el caso de los ingresos, correspondían todos al código -9, que en el diccionario del INDEC se marca que es para los individuos que no registraron una respuesta, por lo que se decidió reemplazarlos por NaN. En el caso de la variable de edad, no hay ninguna codificación oficial respecto a -1, que abarcó la totalidad de valores atípicos, si bien se presupone que es un bebé por nacer dentro del hogar encuestado, se reemplazó por NaN. Luego de la corrección, utilizando la función mask, las variables quedaron limpias de valores negativos como se muestra a continuación.

```python
# definir las columnas a evaluar
posibles_neg = ["P21", "P47T", "CH06"]

# variables que agrupan los valores negativos de las columnas
cont_neg = t1_25[posibles_neg] < 0

print(cont_neg.sum())
```

```
P21     3839
P47T    5405
CH06     290
dtype: int64
```

```python
# reemplazar negativos por NaN en ambos dataframes
#función where, marca como condición los valores menores a 0, y en caso de ser verdadero lo transforma a NaN
t1_2425[posibles_neg] = t1_2425[posibles_neg].mask(t1_2425[posibles_neg] < 0, np.nan)
```

```python
# variables que agrupan los valores negativos de las columnas
cont_neg = t1_2425[posibles_neg] < 0

print(cont_neg.sum())
```

```
P21     0
P47T    0
CH06    0
dtype: int64
```

A continuación, se muestra el gráfico heatmap con los valores nulos por variable, comparado por años:

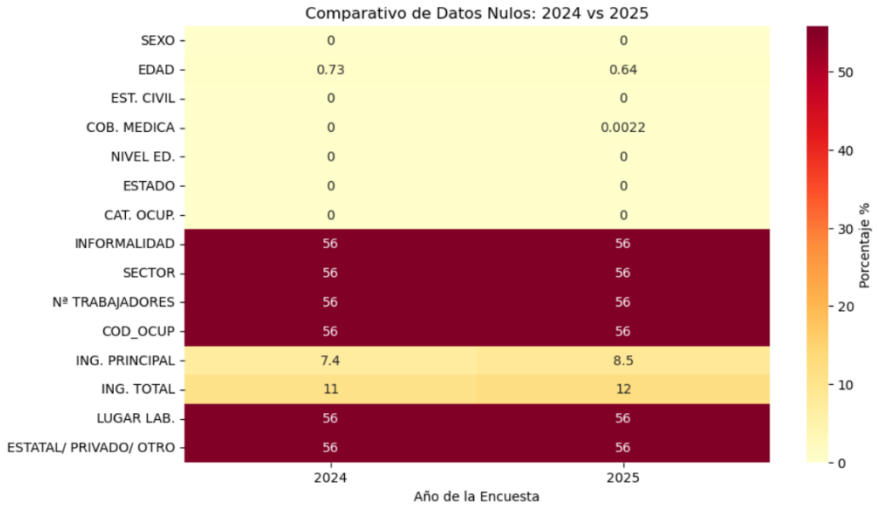

Se puede observar una cantidad marginal de datos nulos para las variables de edad y de cobertura médica, mientras que para el sector de ingresos, el ingreso principal tiene un promedio de 8% de datos no válidos mientras que el ingreso total muestra una media de 11,5%, afectado principalmente por la limpieza de datos negativos.

El mayor valor del gráfico pertenece a las variables relacionadas a la información laboral, con un 56%, esto se puede explicar con la variable “ESTADO”, ya que si una persona no está ocupada, el resto de las columnas se encontrarán en blanco. Se puede observar mejor en la muestra que solo contiene a los no ocupados (“ESTADO ≠ 1”).

```python
[35]: desocupados.head()
```

[35]:

EDAD	EST. CIVIL	COB. MEDICA	NIVEL ED.	ESTADO	CAT. OCUP.	INFORMALIDAD	SECTOR	Nº TRABAJADORES	COD_OCUP	ING. PRINCIPAL	ING. TOTAL	LUGAR LAB.	ESTATAL/ PRIVADO/ OTRO
86.0	4	1.0	2	3	0	NaN	NaN	NaN	NaN	0.0	NaN	NaN	NaN
20.0	5	1.0	4	2	2	NaN	NaN	NaN	NaN	0.0	0.0	NaN	NaN
75.0	3	1.0	6	3	0	NaN	NaN	NaN	NaN	0.0	624000.0	NaN	NaN
20.0	5	1.0	5	3	0	NaN	NaN	NaN	NaN	0.0	0.0	NaN	NaN
14.0	5	1.0	3	3	0	NaN	NaN	NaN	NaN	0.0	0.0	NaN	NaN

Luego se ajustaron por inflación los ingresos correspondientes al año 2024. El multiplicador fue el cociente entre el IPC de marzo de 2025 y el IPC de marzo 2024, dando el resultado de 1,56.

Primer análisis exploratorio

Respecto al análisis exploratorio de los datos, se realizo la construcción de la matriz de correlación de ambos trimestres.

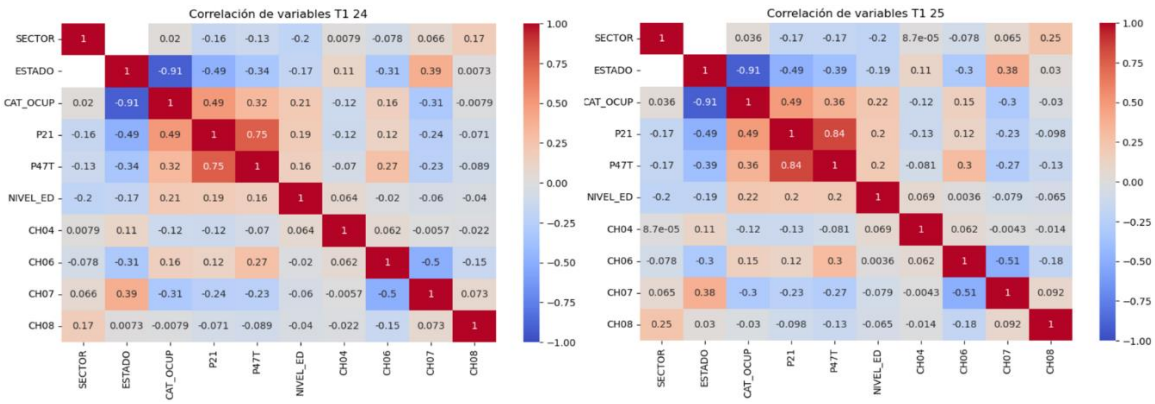

La relación que más queremos resaltar como correlaciones positivas fuertes son entre P21 (ingreso principal) y P47T (ingreso total) con 0,74 y 0,85 para el Primer Trimestre 2024 y 2025 respectivamente. Esto muestra una evolución de 2024 a 2025 donde el ingreso principal se parece más al ingreso total. También se destaca la correlación entre P21, P47T y CAT_OCUP, con 0,49 y 0,32, lo que indica que la categoría ocupacional de una persona influye en los ingresos.

En cuanto a la estadística descriptiva, se compararon los datos de ambos trimestres, y se detectó un cambio en la media del ingreso en ambos trimestres. Si bien se observa un aumento, este no necesariamente implica una mejora real en los ingresos, ya que puede estar explicado por un contexto inflacionario que distorsiona las respuestas de la EPH, y que al momento de publicarla, no represente el ingreso real. Cabe recordar que la inflación del primer cuatrimestre de 2024 fue 44% mientras que para el mismo período de 2025 fue del 7%.

[50]:

	ANO4	SECTOR	ESTADO	CAT_OCUP	P21	P47T	NIVEL_ED	CH04	CH06	CH07	CH08
count	46050.0	20325.00	46050.00	46050.00	46050.00	45969.00	46050.00	46050.00	46050.00	46050.00	46050.00
mean	2024.0	1.66	2.20	1.26	170876.21	270529.53	3.75	1.52	36.29	3.52	2.15
std	0.0	1.60	1.14	1.40	368649.53	525186.83	1.75	0.50	22.21	1.66	2.37
min	2024.0	1.00	0.00	0.00	-14.04	-14.04	1.00	1.00	-1.00	1.00	1.00
25%	2024.0	1.00	1.00	0.00	0.00	0.00	3.00	1.00	18.00	2.00	1.00
50%	2024.0	1.00	3.00	0.00	0.00	106080.00	4.00	2.00	34.00	5.00	1.00
75%	2024.0	2.00	3.00	3.00	240240.00	390000.00	5.00	2.00	53.00	5.00	4.00
99%	2024.0	9.00	4.00	3.00	1404000.00	1872000.00	7.00	2.00	85.51	5.00	12.00
max	2024.0	9.00	4.00	4.00	15600000.00	50856000.00	7.00	2.00	101.00	9.00	123.00

[51]:

	ANO4	SECTOR	ESTADO	CAT_OCUP	P21	P47T	NIVEL_ED	CH04	CH06	CH07	CH08
count	45425.0	20076.00	45425.00	45425.00	45425.00	45350.00	45425.00	45425.00	45425.00	45425.00	45424.00
mean	2025.0	1.70	2.19	1.26	254528.63	409221.23	3.76	1.52	36.79	3.52	2.14
std	0.0	1.65	1.13	1.40	549868.14	688178.32	1.73	0.50	22.14	1.65	2.02
min	2025.0	1.00	0.00	0.00	-9.00	-9.00	1.00	1.00	-1.00	1.00	1.00
25%	2025.0	1.00	1.00	0.00	0.00	0.00	3.00	1.00	18.00	2.00	1.00
50%	2025.0	1.00	3.00	0.00	0.00	128686.00	4.00	2.00	35.00	5.00	1.00
75%	2025.0	2.00	3.00	3.00	380000.00	600000.00	5.00	2.00	54.00	5.00	4.00
99%	2025.0	9.00	4.00	3.00	2000000.00	2807650.00	7.00	2.00	85.00	5.00	12.00
max	2025.0	9.00	4.00	9.00	25000000.00	25000000.00	7.00	2.00	103.00	5.00	123.00

También se verifica un incremento en el desvío estándar de la misma variable, lo que indica una mayor dispersión en los ingresos. Esto sugiere que los valores son cada vez más heterogéneos, dificultando que la media represente de manera precisa la situación general de los individuos.

Nota: los valores de 2024 fueron multiplicados por 1,56.

Conociendo la informalidad laboral

Dado que somos el grupo 3, la definición de informalidad está definida por: propietarios en empresas de hasta cinco empleados, trabajadores por cuenta propia no profesionales y trabajadores familiares no remunerados.

Para que se cumplan esas condiciones, en la base de datos se debían cumplir las siguientes condiciones:

1- ESTADO = 1, CAT. OCUP. = 1, Nª TRABAJADORES = 1 2 3 4 5

2- ESTADO = 1, CAT. OCUP. = 2, NIVEL ED. = 1 2 3 4

3- ESTADO = 1, CAT. OCUP. = 4

Luego de establecer las condiciones, se agregó una columna a la variable de “ocupados” donde se diferenciaba a cada persona según si era formal o informal.

Para compara la informalidad entre años, varones, mujeres, se hizo una tabla.

```
Porcentaje de Informalidad por Año y Sexo (0=Varón, 1=Mujer):
INFORMAL/FORMAL  Formal  Informal
AÑO  SEXO
2024 0            80.95     19.05
     1            86.11     13.89
2025 0            78.80     21.20
     1            84.63     15.37
```

Se pueden visualizar dos hechos, las mujeres tienen menos informalidad que los varones, 7% de diferencia entre ambos años, y que la informalidad aumentó levemente en 2025. El hecho contraintuitivo de la informalidad en mujeres se puede explicar porque el criterio utilizado para medir la informalidad no tiene en cuenta a las amas de casa que, siendo en su mayoría mujeres, no están dentro del grupo de estudio. También, en menor medida puede estar explicado por la edad más temprana de jubilación de las mujeres, que reduce el porcentaje de las mismas ocupadas.

Visualización de histograma y kernels.

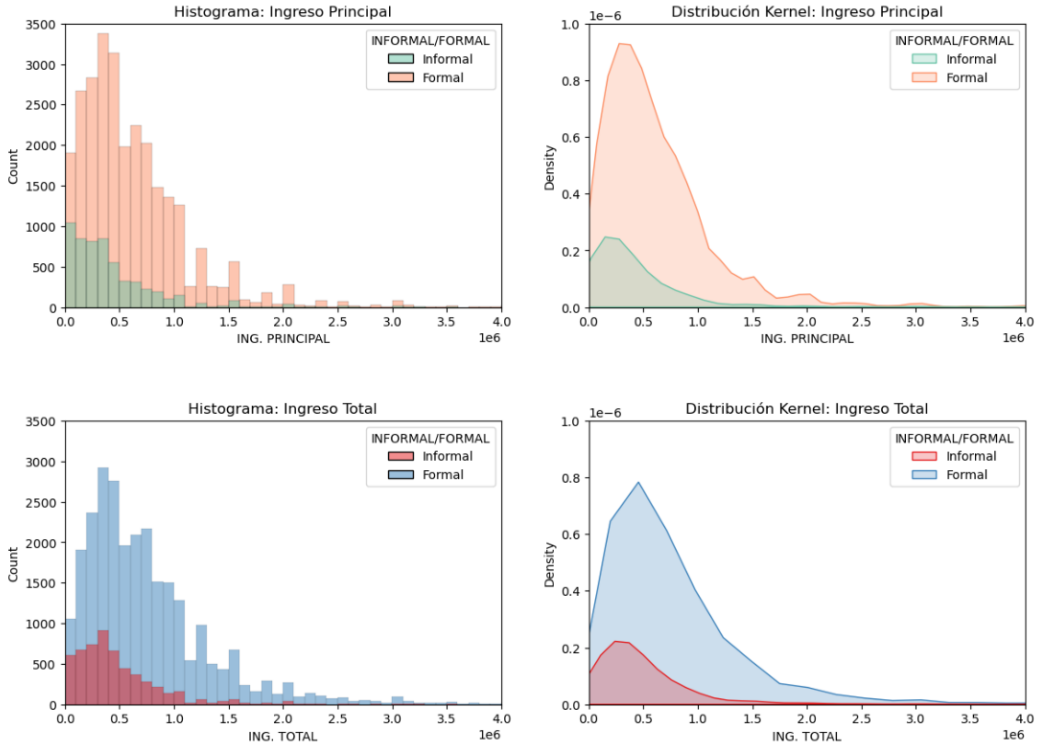

Para ambos casos los ingresos informales son considerablemente inferiores a los formales. También se puede observar cómo los ingresos totales están corridos a la derecha en comparación al ingreso principal, además de que tienen un gráfico menos empinado. Esto último se puede explicar con que el sector con ingresos principales de hasta $500.000 (0.5 en el gráfico), sus ingresos totales están entre $500.000 y $1.000.000. Las limitaciones de estas variables están relacionadas a la subdeclaración de ingresos, en los estratos bajos se omiten por miedo a que se le quite una ayuda social y en los estratos altos por miedo a que se apliquen impuestos.

Herramientas de IA y reflexión

La inteligencia artificial fue una herramienta de apoyo dado por el material provisto en el repositorio del curso. Nos ayudó en cuestiones puntuales de programación, como en la generación del cuadro de estadística descriptiva en el caso que se sugiere un valor de percentil que no viene por default con la función describe. Para la parte inicial del trabajo se utilizó la inteligencia artificial con el fin de obtener el formato genérico de las funciones de Python, destacando a Claude como la herramienta que ofreció mejores resultados por su precisión técnica y obediencia del prompt. En la segunda etapa, se integró Gemini 2.5 Flash como un soporte práctico para completar fragmentos de código y realizar correcciones puntuales en diversas líneas de ejecución. La mayor ayuda de la IA fue en la tercera parte, donde se necesitó para definir las condiciones de formalidad e informalidad en código, además de la asistencia en los gráficos de histogramas y kernels.

El trabajo tomó aproximadamente 12 horas, sumando código, slides e informe.

Apédice

A continuación se mostrarán los prompts utilizados para la resolución del trabajo.

Utilizando, en caso de ser necesario, pandas, numpy y seaborn, dame una línea de código genérico en caso de querer cambiar el nombre de las columnas de un dataframe

Utilizando, en caso de ser necesario, pandas, numpy y seaborn, creá un código simple para generar un heatmap que muestre el porcentaje de valores faltantes (NaN) para las variables seleccionadas en cada año. El código debe ser genérico para poder completar con datos.

Utilizando, en caso de ser necesario, pandas, numpy y seaborn, crea una función que incluya las siguientes condiciones del dataset.

1- ESTADO = 1, CAT. OCUP. = 1, Nª TRABAJADORES = 1 2 3 4 5

2- ESTADO = 1, CAT. OCUP. = 2, NIVEL ED. = 1 2 3 4

3- ESTADO = 1, CAT. OCUP. = 4.

Utilizando, en caso de ser necesario, pandas, numpy y seaborn, genera un gráfico de 4 paneles que compare a trabajadores formales e informales utilizando “ING. PRINCIPAL” y “ING. TOTAL”, con histograma y kernel. En el código se debe poder modificar el límite de valores de los ejes.